

PROGRAMAÇÃO NÃO LINEAR

2º Semestre de 2009

MS629A

PROFA.: SANDRA AUGUSTA SANTOS

sala IM111

Nome: _____ RA: _____

PRIMEIRA PROVA

14/10/2009

Seja cuidadoso no encaminhamento do seu raciocínio.
A clareza da sua argumentação também será avaliada.
Cada questão vale 2.0 pontos.

Questão 1	
Questão 2	
Questão 3	
Questão 4	
Questão 5	
Total	

1. Considere a função quadrática $q(x) = \frac{1}{2}x^T Hx + b^T x + c$, em que $H \in \mathbb{R}^{n \times n}$ é simétrica, $b \in \mathbb{R}^n$ e $c \in \mathbb{R}$. Seja x^* minimizador local de q . Prove que x^* é minimizador global de q .
2. Considere um modelo algorítmico geral para minimização irrestrita com direções de descida. Utilizando **argumentos algébricos, analíticos e geométricos**, explique a diferença entre fazer uma **busca linear exata** e trabalhar com a **condição de Armijo**. Especifique também as situações em que cada uma destas estratégias é mais indicada.
3. Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uma função diferenciável em \tilde{x} e sejam $d^1, d^2, \dots, d^n \in \mathbb{R}^n$ vetores linearmente independentes. Suponha que o mínimo de $f(\tilde{x} + \lambda d^j)$ com $\lambda \in \mathbb{R}$ ocorra em $\lambda = 0$ para todo $j = 1, \dots, n$.
 - (a) Prove que $\nabla f(\tilde{x}) = 0$.
 - (b) Isto implica que \tilde{x} é **minimizador local** de f ? Justifique.
4. Ao minimizar a função $f(x) = 10x_1^2 + x_2^2$ pelo **método de máxima descida com busca exata** a partir do ponto inicial $(1, 1)^T$, quantas iterações você espera realizar para atingir a solução? Justifique.
5. Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida como $f(x) = \sum_{i=1}^n \left(\frac{1}{2} a_i x_i^2 + b_i x_i \right)$ onde $a_i, b_i, i = 1, \dots, n$ são números reais. Exiba **condições suficientes** para que a **direção de Newton** esteja bem definida e seja de descida para qualquer x tal que $\nabla f(x) \neq 0$. Explique como obteve tais condições.

1)

Temos $q(x) = \frac{1}{2}x^T H x + b^T x + c$

$$\nabla q(x) = Hx + b \quad \text{e} \quad \nabla^2 q(x) = H.$$

$\left\{ \begin{array}{l} q \in C^\infty \\ \text{(quadrática)} \end{array} \right.$

Se x^* é minimizador local de q , pelas

CN2, $\boxed{\nabla q(x^*) = 0} \Rightarrow Hx^* + b = 0$ e

$\boxed{\nabla^2 q(x^*) = H \geq 0.}$

um
fzto:

Como a matriz hessiana de q é constante e semi-definida positiva, então q é convexa em \mathbb{R}^n .

Mas então, x^* minimizador local de q em \mathbb{R}^n é minimizador global de q em \mathbb{R}^n .

outro
fzto:

Escrevendo a expansão de Taylor p/ q em torno de x^* , ela é exata pois q é quadrática:

$$q(x) = q(x^*) + \nabla q(x^*)^T (x - x^*) + \frac{1}{2} (x - x^*)^T \nabla^2 q(x^*) (x - x^*)$$

$$q(x) \stackrel{(1)}{=} q(x^*) + \frac{1}{2} (x - x^*)^T H (x - x^*) \stackrel{(2)}{\geq} q(x^*)$$

$$\therefore q(x^*) \leq q(x), \quad \forall x \in \mathbb{R}^n$$

ou seja, x^* é minimizador global de q em \mathbb{R}^n .

2) Problema de minimização restrita:


$$\min_{x \in \mathbb{R}^n} f(x)$$

Um modelo algorítmico para esse problema baseia-se na construção de uma sequência $\{x^k\} \subset \mathbb{R}^n$ na qual $x^{k+1} = x^k + \lambda_k d^k$, d^k é direção de descida e o passo λ_k pode ser calculado minimizando-se exatamente $\phi(\lambda) = f(x^k + \lambda d^k)$ ou apenas impondo-se uma condição de descida suficiente para f .

No primeiro caso, como $\phi'(\lambda) = \nabla f(x^k + \lambda d^k)^T d^k = 0$ então x^{k+1} é tal que $\nabla f(x^{k+1}) \perp d^k$. Geometricamente, isso é fácil de ser visualizado e obtido graficamente para $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ com o mapa de curvas de nível. Algebricamente, no entanto, o cálculo efetivo do passo ótimo da busca linear exata só é simples para f quadrática, em que temos uma fórmula fechada: $\lambda^* = \frac{-(d^k)^T \nabla f(x^k)}{(d^k)^T \nabla^2 f(x^k) d^k}$.

Para f não linear genérica, o cálculo de λ^* envolve encontrar o zero de uma função real não linear de uma variável e em geral este esforço não compensa computacionalmente o benefício de se encontrar um minimizador exato de f ao longo da direção d^k .

Na prática, é mais interessante buscar λ que satisfaça uma condição de descida suficiente, tipo Armijo: queremos λ tal que, para $\alpha \in (0,1)$ dado, $f(x^k + \lambda d^k) \leq f(x^k) + \alpha \lambda \nabla f(x^k)^T d^k$.



Esta condição é indicada para f não linear geral, e juntamente com as condições de tamanho do passo e cond. do ângulo entre d^k e $\nabla f(x^k)$, produz alg. globalmente convergente.

3) a) Seja $\varphi_j(\lambda) = f(\tilde{x} + \lambda d^j)$

$$\text{então } \varphi_j'(\lambda) = \nabla f(\tilde{x} + \lambda d^j)^T d^j$$

Como $\lambda = 0$ minimiza $\varphi_j(\lambda)$, $\forall j = 1, \dots, n$ segue que

$$\varphi_j'(0) = \nabla f(\tilde{x})^T d^j = 0, \quad \forall j = 1, \dots, n.$$


Sendo $\{d^j\}_{j=1}^n$ um conjunto de vetores LI's, o sistema homogêneo.

$$\begin{pmatrix} (d^1)^T \\ \vdots \\ (d^n)^T \end{pmatrix} y = 0 \quad \text{admite apenas a solução trivial.}$$

$$\text{portanto } \nabla f(\tilde{x}) = 0.$$

b) Embora f seja minimizada ao longo de n direções LI's em \mathbb{R}^n , a partir de \tilde{x} , o ponto \tilde{x} pode ser um ponto de sela

Ex:



Em \mathbb{R}^2 , a origem é um ponto de sela, embora seja um ponto de mínimo ao longo das direções $d^1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ e $d^2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$.


4]

A quadrática $f(x) = 10x_1^2 + x_2^2 = \frac{1}{2}(x_1 \ x_2) \begin{pmatrix} 20 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

é uma função estritamente convexa, com minimizador global na origem. Sua Hessiana $\nabla^2 f(x) = \begin{pmatrix} 20 & 0 \\ 0 & 2 \end{pmatrix} = H$ é uma matriz positiva definida e diagonal, portanto as curvas de nível de f são elipses, centradas na origem. Os autovetores de H são os vetores canônicos: $v_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ e $v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$.

O método da máxima descida com busca linear exata só possui convergência finita se $x^0 - x^* = \mu v$, onde x^* é a solução, v é autovetor de H e $\mu \in \mathbb{R}$.

com $x^0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$, portanto, MMD com BLE necessitará de infinitas iterações para chegar na solução.



$$10x_1^2 + x_2^2 = c$$

$$\frac{x_1^2}{1/10} + x_2^2 = c$$

5] $f: \mathbb{R}^n \rightarrow \mathbb{R}$
 $f(x) = \sum_{i=1}^n \left(\frac{1}{2} a_i x_i^2 + b_i x_i \right), a_i, b_i \in \mathbb{R}, i=1, \dots, n$

$$\nabla f(x) = \begin{pmatrix} a_1 x_1 + b_1 \\ a_2 x_2 + b_2 \\ \vdots \\ a_n x_n + b_n \end{pmatrix}, \quad \nabla^2 f(x) = \begin{pmatrix} a_1 & & 0 \\ & a_2 & \\ 0 & & \ddots \\ & & & a_n \end{pmatrix} = A$$

Dirigido de Newton:

$$\nabla^2 f(x^k) d^k = -\nabla f(x^k)$$

d^k estará bem definida e será de descida se $A > 0$. Para que isso ocorra é preciso que $a_i > 0, \forall i=1, \dots, n$.

→ Note que $\nabla^2 f(x^k) = A$ e $d^k = -A^{-1} \nabla f(x^k)$
 $a_i \neq 0 \forall i$ garantem a invertibilidade de A . Para que d^k seja de descida,

$$\nabla f(x^k)^T d^k = -\nabla f(x^k)^T A^{-1} \nabla f(x^k) < 0$$

sempre que $A > 0$, ou seja $a_i > 0, \forall i=1, \dots, n$
 são as condições suficientes procuradas.